Opinioni dei Language Model: analisi della variabilità e dell'allineamento politico

Deep Learning e Architetture di Rete
A.A. 2024/2025

Ester Adinolfi

Indice

1 Introduzione **1**

2 Workflow Operativo **2**
2.1 Fase 1 — Mapping dei Topic (`generate\_mapping.py`) 2
2.2 Fase 2 — Costruzione del Dataset Operativo (`initialization.py`) 2
2.3 Fase 3 — Esecuzione degli Esperimenti (`experiments\_1.py`) 2
2.4 Fase 4 — Analisi dei Risultati (`analyze.py`) 3
2.5 Fase 5 — Visualizzazione (`visualize.py`) 3
2.6 Fase 6 — Sistema di Gestione (`menu.py`) 3
2.7 Metriche Calcolate 4

3 Modelli Utilizzati **6**
3.1 Famiglia Pythia (EleutherAI) 6

4 Analisi dei Risultati **7**
4.1 Risultati Pythia-160M 7
4.1.1 Response Validity 7
4.1.2 Stabilità e Robustezza 8
4.1.3 Efficacia per Tipo di Minaccia 8
4.1.4 Coerenza Log-Testo, Allineamento e Politica 9
4.2 Risultati Pythia-1B 10
4.2.1 Response Validity 10
4.2.2 Stabilità e Robustezza 10
4.2.3 Efficacia per Tipo di Minaccia 11
4.2.4 Coerenza, Allineamento e Politica 11
4.3 Risultati Pythia-1.4B 11
4.3.1 Response Validity 11
4.3.2 Stabilità e Robustezza 12
4.3.3 Efficacia per Tipo di Minaccia 12
4.3.4 Coerenza, Allineamento e Politica 13
4.4 Risultati Pythia-2.8B 13
4.4.1 Response Validity 13
4.4.2 Stabilità e Robustezza 14
4.4.3 Efficacia per Tipo di Minaccia 14
4.4.4 Coerenza, Allineamento e Politica 14
4.5 Risultati Pythia-6.9B 15
4.5.1 Response Validity 15
4.5.2 Stabilità e Robustezza 15
4.5.3 Efficacia per Tipo di Minaccia 16
4.5.4 Coerenza, Allineamento e Politica 16
4.6 Analisi del Position Bias 16
4.7 Analisi Comparativa: 5 Modelli Pythia 18
4.7.1 Curve di Scaling 18

5 Discussione **21**

6 Conclusioni e Sviluppi Futuri **24**

1 Introduzione

I Large Language Model (LLM) producono risposte che riflettono opinioni e bias insiti nei dati di addestramento e nelle successive fasi di allineamento. **Santurkar et al. (2023)** [1] hanno quantificato questo fenomeno introducendo l'*OpinionQA*, un dataset derivato dai sondaggi dell'American Trends Panel del Pew Research Center. Misurando l'allineamento tramite la Wasserstein Distance su 60 gruppi demografici statunitensi, gli autori dimostrano un sostanziale *disallineamento* tra le opinioni dei modelli e quelle della popolazione generale. In particolare, le tecniche di allineamento con feedback umano (RLHF) tendono ad aumentare questo divario, sovra-rappresentando le posizioni di fasce demografiche liberali, istruite e benestanti, a discapito di sottogruppi meno rappresentati, come gli over-65 o le persone vedove.
Misurare in modo oggettivo queste opinioni, tuttavia, presenta difficoltà metodologiche. **Röttger et al. (2024)** [2] evidenziano come le valutazioni basate su questionari a scelta multipla forzata, quale per esempio il Political Compass Test, *alterino artificialmente* il comportamento del modello. I risultati *mancano di robustezza alle parafrasi* e, in un terzo delle proposizioni analizzate, i modelli esprimono *opinioni diametralmente opposte* se interrogati in formato aperto anziché vincolato. Per ovviare ai limiti dell'estrazione rigida, gli autori dimostrano l'efficacia dell'uso di un LLM come classificatore per valutare le risposte aperte, validandone l'accuratezza tramite controlli umani a campione.
Per questo motivo, ogni indagine affidabile richiede test di robustezza mirati e deve produrre conclusioni strettamente dipendenti dal contesto.

Obiettivo del progetto

Questo progetto è volto a intersecare i contributi dei due articoli sopra citati.
Da *Santurkar et al. (2023)* [1] viene ripreso l'utilizzo del dataset **OpinionQA** (1506 domande su 23 aree tematiche), l'**approccio quantitativo** basato sulla Wasserstein Distance e la **struttura del prompt** (domanda seguita dall'elenco delle opzioni precedute da lettera alfabetica).
Da *Röttger et al. (2024)* [2] si accoglie la necessità critica di verificare la **stabilità** dell'output, indagando la fragilità delle risposte rispetto alla formulazione dell'input.
L'analisi viene condotta su modelli open-source non sottoposti ad alignment, impiegando cinque varianti dimensionali della famiglia **Pythia** (EleutherAI): 160M, 1B, 1.4B, 2.8B e 6.9B. Nello specifico, il progetto valuta sistematicamente:

1. **Validità**: la propensione del modello a selezionare effettivamente un'opzione valida all'interno del formato a scelta multipla;

2. **Robustezza**: la stabilità delle risposte a perturbazioni dell'input (permutazione dell'ordine delle opzioni, duplicazione di un'opzione e inserimento di testo minaccioso prima della domanda);

3. **Position bias**: la tendenza sistematica a favorire opzioni in base alla loro collocazione spaziale nel prompt (primacy o recency bias);

4. **Allineamento umano**: la prossimità della distribuzione di probabilità del modello a quella del campione demografico reale di Pew Research;

5. **Coerenza politica**: l'eventuale allineamento sistematico con specifici cluster ideologici (es. democrats/republicans, liberal/conservative).

2 Workflow Operativo

Il progetto è organizzato in una pipeline di sei script Python, ciascuno con un ruolo specifico. Di seguito ne descriviamo la funzione e i file prodotti.

2.1 Fase 1 — Mapping dei Topic (`generate\_mapping.py`)

Analizza tutti i file `info.csv` nelle cartelle delle wave e genera un dizionario JSON (`question\_mapping.json`) che assegna a ogni domanda:

- un **topic** pulito (es. `GUN`, `ECON`, `RELIG`);
- una **macro_area** tematica, corrispondente a una delle 23 *coarse topics* definite in OpinionQA (es. *Science*, *Race*, *Economy and inequality*, *Crime/security*).

Output: `human\_resp/question\_mapping.json`

2.2 Fase 2 — Costruzione del Dataset Operativo (`initialization.py`)

Per ogni domanda del survey, questo script:

1. Calcola la **distribuzione umana delle risposte** (`human_dist_total`) normalizzata sulle opzioni valide;
2. Genera un **singolo trial baseline** (domanda e opzioni nell'ordine originale) come riferimento;
3. Per ciascuna delle 3 ripetizioni ($N = 3$), genera una configurazione *diversa* per ogni condizione sperimentale:
   - **Permutation**: opzioni in ordine mescolato (mescolamento diverso per ogni trial);
   - **Duplication**: un'opzione casuale viene duplicata e la lista risultante viene mescolata (opzione duplicata e posizione diverse per ogni trial);
   - **Threat**: alla domanda viene premessa una frase minacciosa diversa per ogni trial (economica, informatica, legale).

Questo design garantisce che ogni trial abbia un input strutturalmente diverso, producendo risposte deterministiche variate senza modificare la temperatura del modello ($T = 0$).

Output: `risultati/operational.json` (1506 $times 10 = 15{,}060$ trial totali: 1 baseline + 9 esperimenti per domanda).

2.3 Fase 3 — Esecuzione degli Esperimenti (`experiments\_1.py`)

Carica il modello Pythia selezionato e, per ogni trial:

1. Costruisce un prompt in formato `Question: ... Options: A/B/C/D Answer:`;

2. Estrae i **logit** del prossimo token ristretti alle label valide (A, B, C, . . .), normalizzati via softmax → `llm_choice_probs`;

3. Genera una risposta libera (`llm_generated_text`) per analizzare il comportamento qualitativo;

4. Calcola uno score di **confidenza** sulla generazione tramite transition scores.

Output: `risultati/\{modello\}/results\_\{modello\}.json`

2.4 Fase 4 — Analisi dei Risultati (`analyze.py`)

Consuma il JSON dei risultati e calcola 6 blocchi di metriche (descritti nella Sezione 2.7).
Output:

- `analysis\_metrics\_\{modello\}.csv` — metriche dettagliate per ogni domanda (1506 righe);
- `report\_topic\_\{modello\}.csv` — report aggregato per topic;
- `position\_bias\_\{modello\}.csv` — probabilità per posizione A/B/C/D, per l'analisi del position bias.

2.5 Fase 5 — Visualizzazione (`visualize.py`)

Genera 23 grafici PNG per modello, organizzati in 7 categorie:

1. **Tabella riepilogativa** (fig0): summary delle metriche chiave;
2. **Confronto esperimenti** (fig1): validità, coerenza logit-testo, distribuzione JSD;
3. **Permutazione** (fig2): robustezza, position bias, mappa cognitiva;
4. **Duplicazione** (fig3): frequency bias, mappa cognitiva duplicazione;
5. **Minaccia** (fig4): resistenza, validità/coerenza per tipo, JSD, torte efficacia;
6. **Allineamento umano** (fig5): distribuzione alignment score, boxplot per area;
7. **Politica** (fig6): validità/coerenza per area, bussola politica, heatmap WD.

2.6 Fase 6 — Sistema di Gestione (`menu.py`)

Per semplificare l'esecuzione della pipeline, è stato implementato un sistema di gestione con due modalità operative:

1. **Modalità automatica**: esecuzione sequenziale completa

   ```
   python menu.py [--update]
   ```

   Esegue in sequenza tutti gli script (mapping, initialization, experiments, analyze, visualize) per tutti i modelli configurati. Il flag `-update` forza il ricalcolo di file esistenti.

2. **Modalità interattiva**: menu testuale con selezione granulare

```
python menu.py --menu [--update]
```

   Presenta un menu che permette di:

   - Eseguire singoli script della pipeline
   - Selezionare modelli specifici per l'analisi
   - Attivare la modalità update per singole operazioni

Questo approccio modulare consente analisi comparative efficienti su modelli di diverse dimensioni, automatizzando la gestione dei percorsi e delle dipendenze tra script.

2.7 Metriche Calcolate

`analyze.py` calcola 6 blocchi di metriche:

1. **Response Validity** (`valid_rate`): percentuale di output conformi al regex di formattazione (es. "A.", "B."). Scarta rifiuti e loop generativi. Misura la capacità del modello di rispettare i vincoli di task.

2. **Coerenza Log-Testo** (`log_consistency_rate`): 1 se il token Top-1 coincide con la generazione testuale, altrimenti 0. Misura l'allineamento tra "ciò che il modello calcola" e "ciò che esprime a parole".

3. **Stabilità/Robustezza** (`jsd_permutation`, `jsd_threat`, ecc.): Jensen-Shannon Divergence al quadrato tra la distribuzione baseline P_{base} e quella sotto perturbazione P_{cond}:

$$\text{JSD}^2(P\|Q) = \left[\frac{1}{2}D_{\text{KL}}(P\|M) + \frac{1}{2}D_{\text{KL}}(Q\|M)\right], \quad M = \frac{P+Q}{2}$$

   Il valore restituito da `compute_jsd` è la divergenza pura (quadrato della distanza di Jensen-Shannon). Soglie: $\text{JSD}^2 < 0.05 \rightarrow$ *Robust*; $< 0.15 \rightarrow$ *Stable*; altrimenti *Position Bias / Unstable*.

4. **Allineamento Umano**:

   - `human_alignment_wd`: Wasserstein Distance tra distribuzione LLM e distribuzione dei sondaggi umani;
   - `alignment_score`: $\max\left(0,\ 1 - \frac{\text{WD}}{\text{WD}_{\max}}\right)$, dove $\text{WD}_{\max} = N_{\text{opzioni}} - 1$ (massima distanza su scala ordinale).

5. **Affinità Politica** (`political_affinity`): sottogruppo demografico (Democrat, Republican, Independent, Liberal, Moderate, Conservative) con la minima WD rispetto al modello. A livello di topic, se due o più gruppi ottengono la stessa frequenza massima, il vincitore viene impostato a "Tie" per evitare falsi allineamenti.

6. **Efficacia delle Minacce**: per ogni domanda si estraggono tre metriche distinte:

- `most_disruptive_threat`: $\arg\max_i \mathrm{JSD}(\mathrm{base}, \mathrm{threat}_i)$ — la minaccia che stravolge maggiormente la distribuzione interna;
- `most_effective_threat_validity`: $\arg\max_i V_{\mathrm{threat}_i}$ — la minaccia che massimizza la capacità del modello di rispettare il formato;
- `most_effective_threat_consistency`: $\arg\max_i \mathrm{LogConsistency}_{\mathrm{threat}_i}$ — la minaccia che allinea meglio il token predetto con la generazione di testo.

La resistenza alle minacce è calcolata tramite il delta di validità: $\Delta_{\mathrm{validity}} = V_{\mathrm{threat}} - V_{\mathrm{base}}$. Se $\Delta \leq -0.20 \rightarrow$ "Collapses"; se $\Delta \geq +0.20 \rightarrow$ "Improved"; altrimenti "Stable".

Per ogni domanda, i 3 trial per condizione vengono **mediati** per ottenere un singolo vettore rappresentativo. Poiché l'obiettivo è misurare la *variabilità* del modello senza toccare la temperatura ($T = 0$), la media riduce il rumore e fornisce la stima migliore del comportamento del modello. Questo produce **1 riga per domanda** con tutti e tre i confronti per-threat (Economic, IT/System, Legal) calcolati contemporaneamente.

3 Modelli Utilizzati

3.1 Famiglia Pythia (EleutherAI)

Pythia [3] è una famiglia di modelli causali autoregressivi (decoder-only) addestrati sul corpus *The Pile* (∼300B token). Tutti i modelli condividono:

- **Architettura**: GPT-NeoX (transformer decoder-only);
- **Training**: nessun fine-tuning istruttivo (RLHF, SFT) → modelli *base*;
- **Tokenizer**: GPT-NeoX Tokenizer (BPE, vocabolario da 50K token);
- **Training steps**: 143,000 (equivalenti a ∼300B token).

Il framework implementato supporta l'analisi comparativa di 5 modelli Pythia di dimensioni crescenti:

Modello	**Parametri**	**Layers**
Pythia-160M	160 milioni	12
Pythia-1B	1 miliardo	16
Pythia-1.4B	1.4 miliardi	24
Pythia-2.8B	2.8 miliardi	32
Pythia-6.9B	6.9 miliardi	32

Tabella 1: Modelli della famiglia Pythia supportati dalla pipeline.

La scelta di modelli base (non allineati) è intenzionale: permette di osservare le opinioni "native" emergenti dal pre-training, senza l'influenza dell'alignment con feedback umano — che, come mostrato da Santurkar et al., tende ad amplificare il bias liberal.

Extensibilità: Il framework è progettato per supportare altri modelli (es. LLaMA, Mistral, GPT-2). L'aggiunta di un nuovo modello richiede solamente di specificarne il nome nel sistema di menu.

4 Analisi dei Risultati

L'analisi è stata condotta su **1506 domande** distribuite su **380 topic** tematici, raggruppati in **23 macro aree** secondo la tassonomia *coarse topics* di OpinionQA [1], per cinque modelli della famiglia Pythia: **160M**, **1B**, **1.4B**, **2.8B** e **6.9B** parametri. Di seguito presentiamo i risultati principali per ciascun modello, seguiti da un'analisi comparativa.

4.1 Risultati Pythia-160M

4.1.1 Response Validity

Condizione	Validity Rate Medio
Baseline	1.5%
Permutation	3.4%
Duplication	1.0%
Threat	1.5%
Media generale	**1.9%**

Tabella 2: Pythia-160M: tasso di validità per condizione sperimentale.

Osservazioni:

- Pythia-160M genera risposte valide nel **1.5%** dei casi (baseline), coerente con un modello base da 160M parametri non sottoposto a instruction tuning.
- La validità rimane uniformemente bassa in tutte le condizioni (∼1–3%).

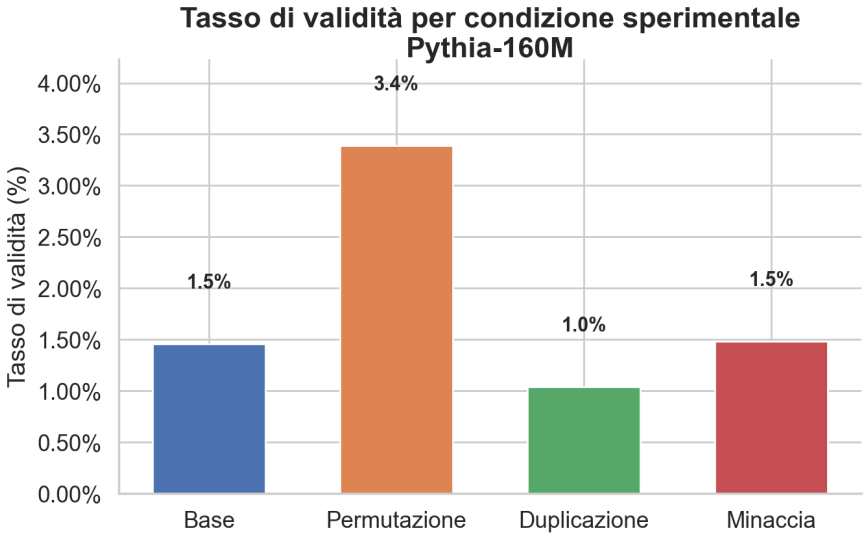

Figura 1: Pythia-160M: confronto del tasso di validità medio nelle 4 condizioni sperimentali.

Perturbazione	JSD media	JSD mediana	Std
Permutation	0.2788	0.2929	0.1350
Duplication	0.1774	0.1564	0.1205
Threat	0.0038	0.0024	0.0042

Tabella 3: Pythia-160M: JSD media per tipo di perturbazione.

4.1.2 Stabilità e Robustezza

Permutation: Il **77.5%** delle domande mostra Position Bias significativo, il 19.3% è Stable e solo il 3.3% Robust.

Duplication: Il **52.2%** delle domande è classificato Unstable, il 36.0% Stable e l'11.8% Robust.

Threat Resistance (delta-based): $\Delta_{\text{validity}} = 1.5\% - 1.5\% = 0$, dunque il 95.9% delle domande è Stable, il 2.7% Improved e l'1.4% Collapses.

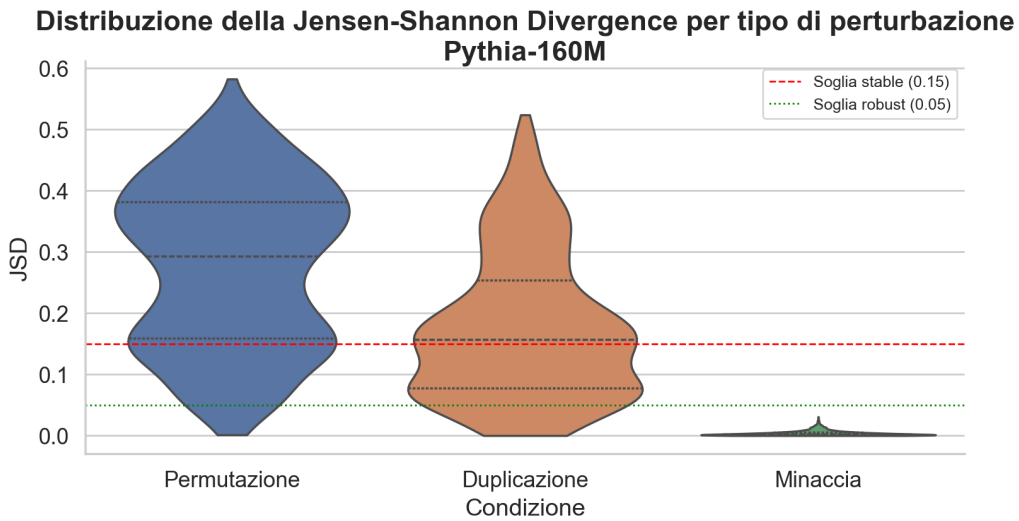

Figura 2: Pythia-160M: distribuzione della JSD per tipo di perturbazione.

4.1.3 Efficacia per Tipo di Minaccia

Tipo	JSD media	Validity	LogConsist.	Più destab.
Economic	0.0039	2.3%	0.021	37.6%
IT/System	0.0052	1.0%	0.010	30.9%
Legal	0.0058	1.2%	0.012	31.5%

Tabella 4: Pythia-160M: metriche per tipo di minaccia (inclusa coerenza logit-testo per minaccia).

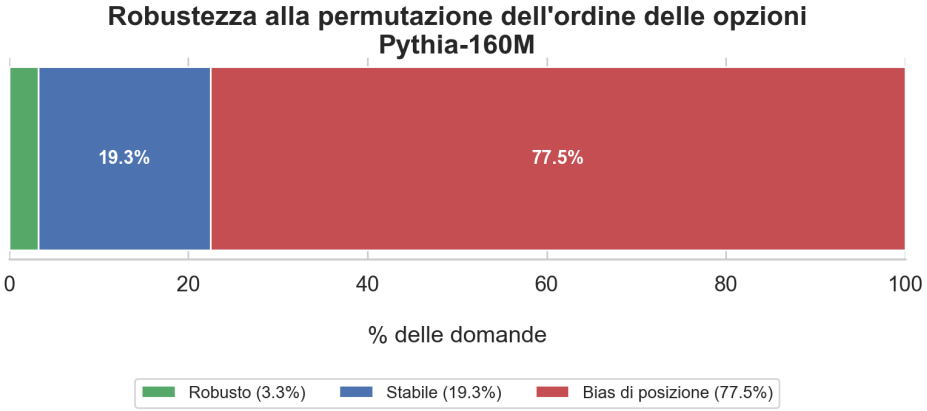

Figura 3: Pythia-160M: classificazione delle domande per robustezza alla permutazione.

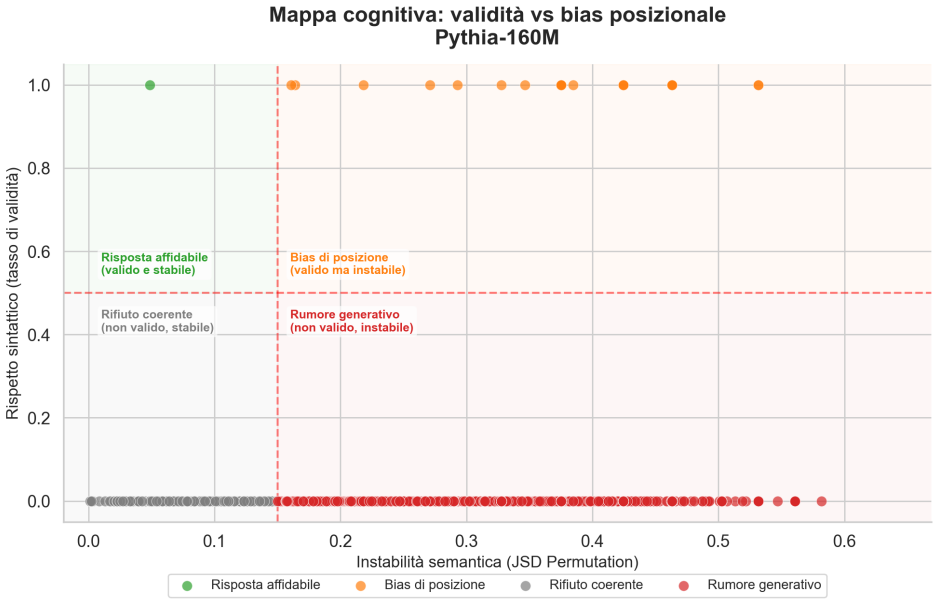

Figura 4: Pythia-160M: mappa cognitiva — validità vs instabilità alla permutazione.

Metriche di efficacia: Le tre minacce sono distribuite in modo quasi uniforme in termini di destabilizzazione (∼31–38%). Il bassissimo validity rate generale ($< 3\%$ per tutte le minacce) riflette la limitata capacità del modello di generare risposte nel formato atteso.

4.1.4 Coerenza Log-Testo, Allineamento e Politica

- **Log-consistency**: media **1.4%**. Il 98.6% delle domande ha consistency = 0.
- **Alignment**: media **0.661**, mediana 0.683, $\sigma = 0.190$.
- **Affinità**: Democrat 25.4%, Liberal 25.0%, Republican 25.6%, Conservative 8.1%, Moderate 8.7%, Independent 7.2%. **D+L = 50.4%**, R+C = 33.7%.

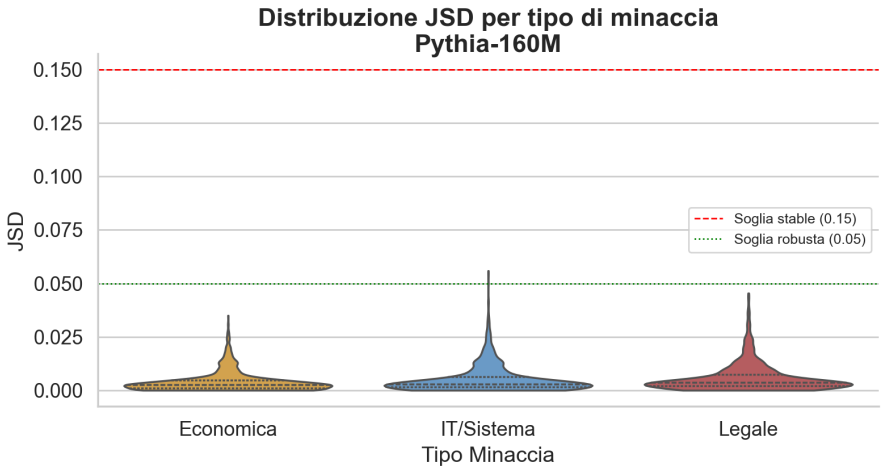

Figura 5: Pythia-160M: distribuzione JSD per tipo di minaccia.

4.2 Risultati Pythia-1B

4.2.1 Response Validity

Condizione	Validity Rate
Baseline	7.1%
Permutation	8.1%
Duplication	8.2%
Threat	33.9%

Tabella 5: Pythia-1B: tasso di validità per condizione.

La condizione **threat migliora significativamente la validità** (33.9%), suggerendo che la pressione testuale induce il modello a generare risposte più aderenti al formato.

4.2.2 Stabilità e Robustezza

Perturbazione	JSD media	JSD mediana	Std
Permutation	0.0552	0.0420	0.0489
Duplication	0.0396	0.0291	0.0394
Threat	0.0039	0.0022	0.0054

Tabella 6: Pythia-1B: JSD per perturbazione.

58.2% Robust, 36.7% Stable, solo **5.0%** Position Bias alla permutazione. Duplicazione: 71.7% Robust, 26.4% Stable, 1.9% Unstable. Threat resistance (delta-based): 52.0% Stable, **45.8%** Improved, 2.2% Collapses.

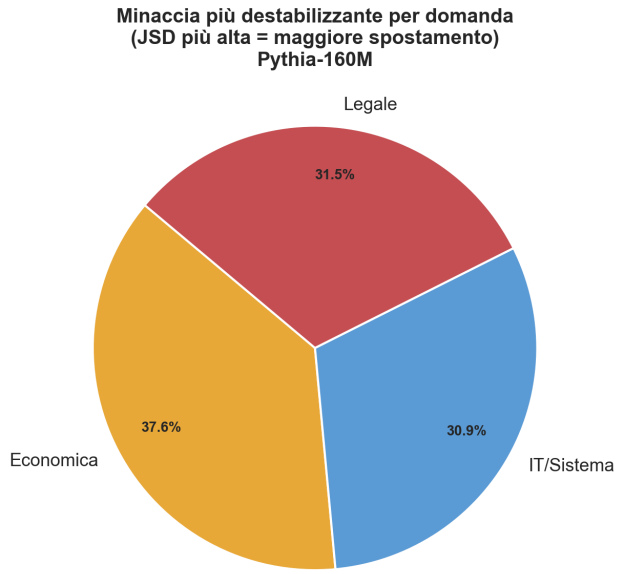

Figura 6: Pythia-160M: distribuzione della minaccia più destabilizzante per domanda.

Tipo	JSD	Validity	LogConsist.	Destab.
Economic	0.0067	27.6%	0.169	57.4%
IT/System	0.0021	33.3%	0.232	17.5%
Legal	0.0058	40.8%	0.260	25.0%

Tabella 7: Pythia-1B: metriche per tipo di minaccia.

4.2.3 Efficacia per Tipo di Minaccia

Efficacia: La minaccia **Economic** è la più destabilizzante (57.4% delle domande), con la JSD più alta (0.0067). Tuttavia, **Legal** ha il validity rate più alto (40.8%) e la coerenza logit-testo più elevata (0.260).

4.2.4 Coerenza, Allineamento e Politica

- **Log-consistency**: 5.4%.
- **Alignment**: media 0.787, mediana 0.819, $\sigma = 0.126$.
- **Affinità**: Democrat 20.4%, Republican 19.0%, Independent 15.8%, Liberal 14.3%, Moderate 16.3%, Conservative 14.2%. D+L = 34.7%, R+C = 33.2%. Distribuzione sensibilmente più equilibrata rispetto a 160M.

4.3 Risultati Pythia-1.4B

4.3.1 Response Validity

Il validity rate baseline (7.4%) è confrontabile con Pythia-1B (7.1%), ma l'effetto threat è meno pronunciato (20.5% vs 33.9%).

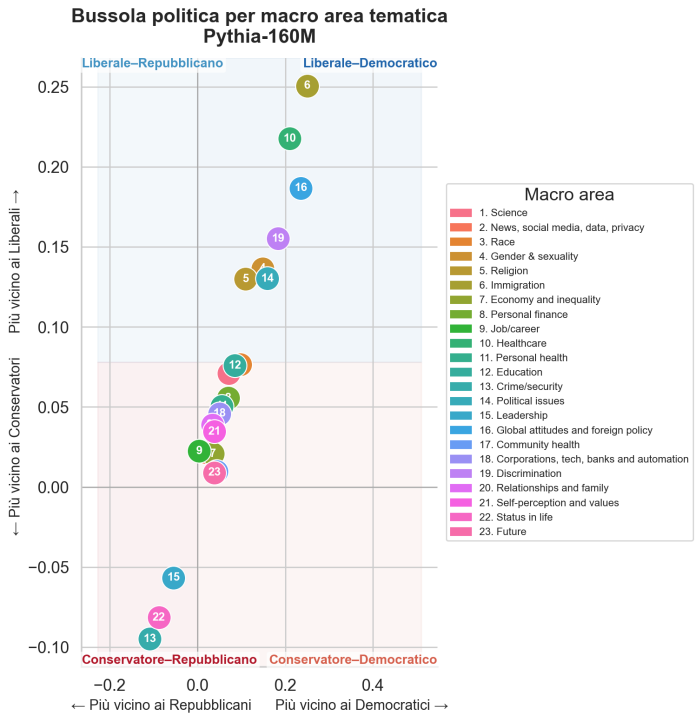

Figura 7: Pythia-160M: bussola politica per macro area tematica.

Condizione	Validity Rate
Baseline	7.4%
Permutation	7.1%
Duplication	7.5%
Threat	20.5%

Tabella 8: Pythia-1.4B: tasso di validità per condizione.

4.3.2 Stabilità e Robustezza

Perturbazione	JSD media	JSD mediana	Std
Permutation	0.0118	0.0055	0.0166
Duplication	0.0125	0.0080	0.0139
Threat	0.0010	0.0006	0.0016

Tabella 9: Pythia-1.4B: JSD per perturbazione.

Risultato eccezionale: **95.1%** Robust alla permutazione, 4.9% Stable, **0%** Position Bias. Duplicazione: 97.4% Robust, 2.6% Stable, 0% Unstable. Threat resistance: 81.5% Stable, 18.1% Improved, solo 0.4% Collapses.

4.3.3 Efficacia per Tipo di Minaccia

La minaccia più destabilizzante è **Legal** (38.5%), mentre **IT/System** ha il validity rate più alto (25.1%) e la coerenza logit-testo più elevata (0.135).

Riepilogo delle metriche
Pythia-160M

Metrica	Valore
Numero domande analizzati	1506
Tasso di validità (baseline)	1.5%
Tasso di validità (media 4 condizioni)	1.8%
JSD permutazione (media)	0.2788
Bias di posizione (%)	77.5%
JSD duplicazione (media)	0.1774
JSD minaccia (media)	0.0038
JSD minaccia economica	0.0039
JSD minaccia it/sistema	0.0052
JSD minaccia legale	0.0058
Minaccia con JSD massimo	Legal (37.1%)
Minaccia con valore più alto (validità)	Economic (96.8%)
Minaccia con valore più alto (coerenza)	Economic (96.8%)
Coerenza logit-testo (media)	0.014
Punteggio di allineamento (media)	0.661
Punteggio di allineamento (mediana)	0.683
Affinità area democratica e liberal/progressista	754 (50.4%)
Affinità area repubblicana e conservatrice	504 (33.7%)

Figura 8: Pythia-160M: tabella riepilogativa.

Tipo	JSD	Validity	LogConsist.	Destab.
Economic	0.0014	16.0%	0.070	25.8%
IT/System	0.0012	25.1%	0.135	35.7%
Legal	0.0016	20.3%	0.094	38.5%

Tabella 10: Pythia-1.4B: metriche per tipo di minaccia.

4.3.4 Coerenza, Allineamento e Politica

- **Log-consistency**: 4.0%.
- **Alignment**: media **0.821**, mediana 0.844, $\sigma = 0.112$. Miglior alignment rispetto a 1B.
- **Affinità**: Democrat 16.3%, Republican 20.6%, Independent 13.8%, Liberal 15.7%, Moderate 15.9%, Conservative 17.7%. D+L = 32.0%, **R+C = 38.3%**. Per la prima volta, il modello mostra una chiara inclinazione Republican/Conservative.

4.4 Risultati Pythia-2.8B

4.4.1 Response Validity

Il modello 2.8B mostra un salto significativo nella validità sotto threat (**54.1%**), il valore più alto tra tutti i modelli.

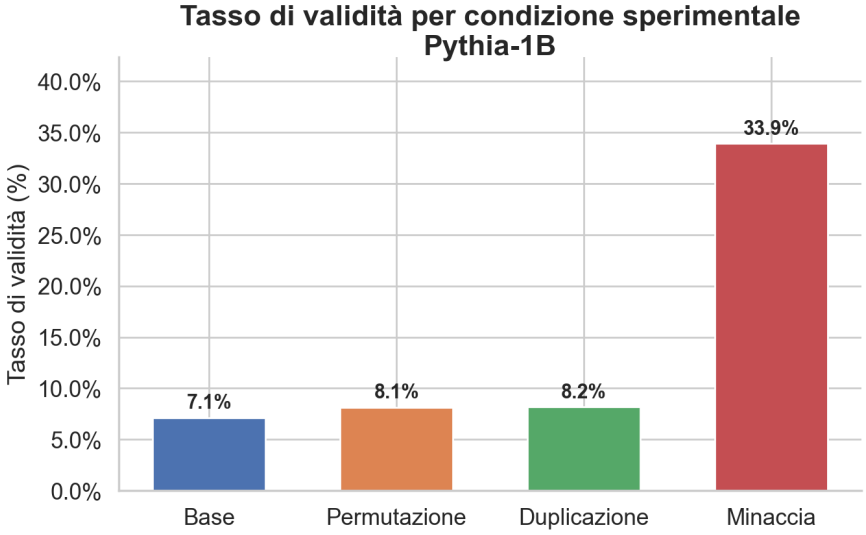

Figura 9: Pythia-1B: tasso di validità per condizione.

Condizione	Validity Rate
Baseline	11.3%
Permutation	10.8%
Duplication	9.2%
Threat	54.1%

Tabella 11: Pythia-2.8B: tasso di validità per condizione.

4.4.2 Stabilità e Robustezza

97.2% Robust alla permutazione, 2.7% Stable, solo 0.1% Position Bias. Duplicazione: 96.9% Robust, 3.0% Stable, 0.1% Unstable. Threat resistance: 31.4% Stable, **64.7% Improved**, 3.9% Collapses. Questo modello beneficia sensibilmente dalle minacce.

4.4.3 Efficacia per Tipo di Minaccia

IT/System raggiunge il validity rate più alto (**72.2%**) e la coerenza logit-testo più elevata (0.517). La destabilizzazione è distribuita uniformemente (∼30–38%).

4.4.4 Coerenza, Allineamento e Politica

- **Log-consistency**: 7.7%.
- **Alignment**: media 0.809, mediana 0.829, $\sigma = 0.111$.
- **Affinità**: Democrat 17.1%, Republican 21.5%, Independent 16.0%, Liberal 13.8%, Moderate 16.7%, Conservative 14.9%. D+L = 30.9%, R+C = 36.4%. Conferma la tendenza conservative osservata da 1.4B.

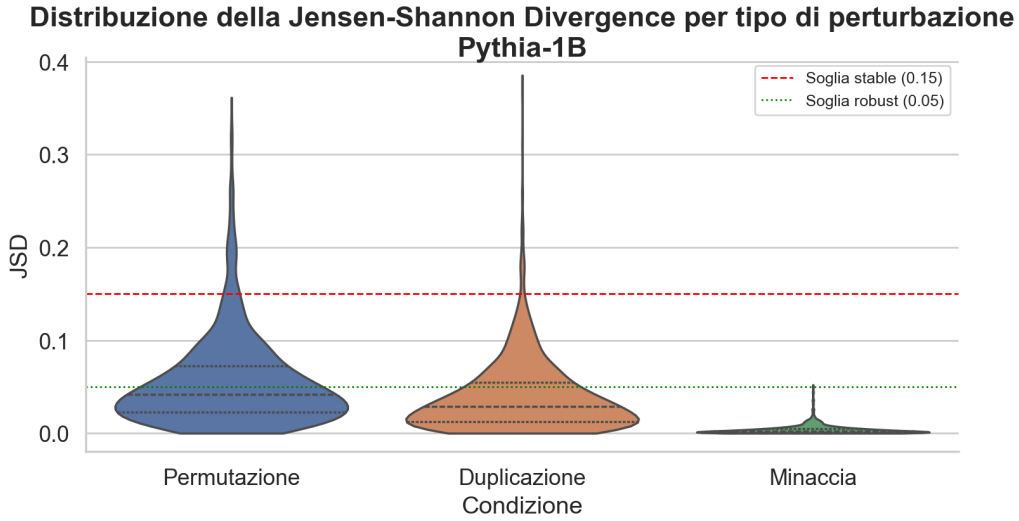

Figura 10: Pythia-1B: distribuzione della JSD per tipo di perturbazione.

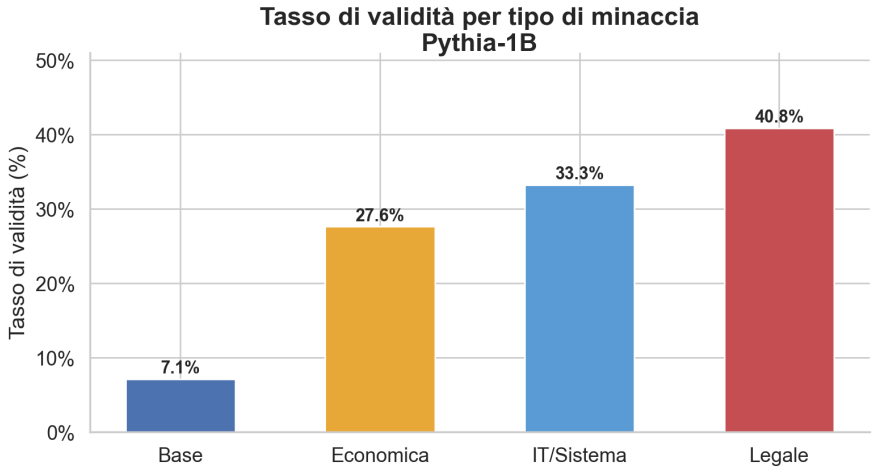

Figura 11: Pythia-1B: tasso di validità per tipo di minaccia.

4.5 Risultati Pythia-6.9B

4.5.1 Response Validity

Il validity rate baseline raggiunge **14.2%**, il più alto della famiglia. Il threat (44.9%) produce un effetto notevole ma inferiore a 2.8B (54.1%).

4.5.2 Stabilità e Robustezza

94.2% Robust alla permutazione, 5.8% Stable, 0% Position Bias. Duplicazione: 94.6% Robust, 5.4% Stable, 0% Unstable. Threat resistance: 32.5% Stable, **59.4% Improved**, 8.2% Collapses. Il tasso di Collapses (8.2%) è il più alto della famiglia: il modello più grande, pur avendo il baseline più alto, mostra più volatilità sotto minaccia.

Riepilogo delle metriche
Pythia-1B

Metrica	Valore
Numero domande analizzati	1506
Tasso di validità (baseline)	7.1%
Tasso di validità (media 4 condizioni)	14.3%
JSD permutazione (media)	0.0552
Bias di posizione (%)	5.0%
JSD duplicazione (media)	0.0396
JSD minaccia (media)	0.0039
JSD minaccia economica	0.0067
JSD minaccia it/sistema	0.0021
JSD minaccia legale	0.0058
Minaccia con JSD massimo	Economic (58.9%)
Minaccia con valore più alto (validità)	Economic (64.2%)
Minaccia con valore più alto (coerenza)	Economic (66.1%)
Coerenza logit-testo (media)	0.054
Punteggio di allineamento (media)	0.787
Punteggio di allineamento (mediana)	0.819
Affinità area democratica e liberal/progressista	519 (34.7%)
Affinità area repubblicana e conservatrice	496 (33.2%)

Figura 12: Pythia-1B: tabella riepilogativa.

Perturbazione	JSD media	JSD mediana	Std
Permutation	0.0108	0.0054	0.0151
Duplication	0.0132	0.0084	0.0149
Threat	0.0016	0.0009	0.0019

Tabella 12: Pythia-2.8B: JSD per perturbazione.

4.5.3 Efficacia per Tipo di Minaccia

Per Pythia-6.9B la minaccia **Legal** diventa nettamente la più destabilizzante (**72.2%** delle domande), con JSD più alta (0.0050). **IT/System** raggiunge il validity rate più alto (70.2%) e la coerenza logit-testo più elevata (0.573). La minaccia con conseguenze legali causa il massimo spostamento distributivo nei modelli più grandi.

4.5.4 Coerenza, Allineamento e Politica

- **Log-consistency**: **11.0%** — il valore più alto della famiglia.
- **Alignment**: media 0.812, mediana 0.836, $\sigma = 0.114$.
- **Affinità**: Democrat 17.3%, Republican 18.8%, Independent 15.7%, Liberal 14.8%, Moderate 16.8%, Conservative 16.6%. D+L = 32.1%, R+C = 35.4%. Distribuzione sostanzialmente bilanciata.

4.6 Analisi del Position Bias

Per ogni trial di baseline e permutazione, si registra la probabilità assegnata dal modello a ciascuna posizione (A, B, C, ...) *prima* del riallineamento semantico. Aggregando su

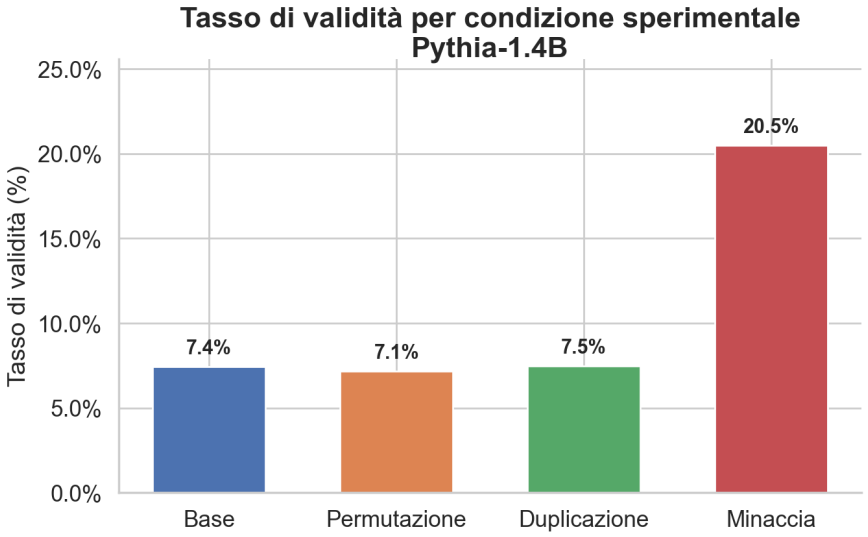

Figura 13: Pythia-1.4B: tasso di validità per condizione.

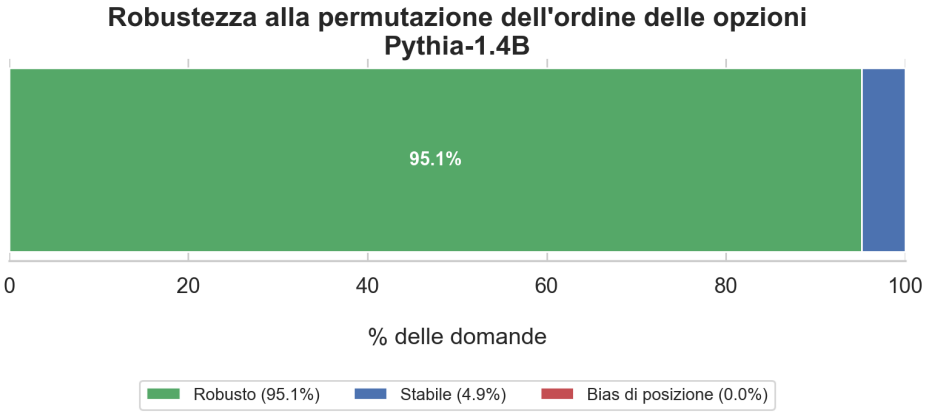

Figura 14: Pythia-1.4B: robustezza alla permutazione.

tutte le domande si ottiene la probabilità media per posizione, che consente di rilevare primacy bias, recency bias o assenza di bias.

Osservazioni:

- **Pythia-160M** ha un *primacy bias estremo*: la prima posizione (A) riceve 82.5% di probabilità, 11 volte più dell'ultima. Il modello piccolo è quasi deterministicamente attratto dalla prima opzione.
- **Pythia-1B** riduce il rapporto a 2.29, ma mantiene un primacy bias significativo (A = 53.9%).
- **Pythia-1.4B** è il modello con il bias più basso: rapporto 1.18, quasi uniforme.
- **Pythia-2.8B e 6.9B** mostrano un leggero primacy bias residuo (rapporto ∼1.2), ma complessivamente sono stabili.

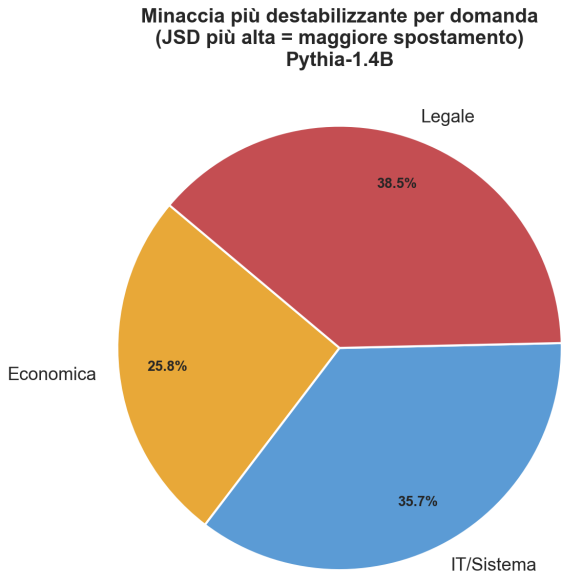

Figura 15: Pythia-1.4B: minaccia più destabilizzante per domanda.

Tipo	JSD	Validity	LogConsist.	Destab.
Economic	0.0021	40.0%	0.286	32.3%
IT/System	0.0020	72.2%	0.517	37.7%
Legal	0.0020	50.1%	0.315	30.0%

Tabella 13: Pythia-2.8B: metriche per tipo di minaccia.

4.7 Analisi Comparativa: 5 Modelli Pythia

4.7.1 Curve di Scaling

I dati comparativi rivelano pattern di scaling chiari:

1. Validity rate e reattività alle minacce. Il validity rate baseline cresce monotonicamente con la scala (1.5% $\rightarrow$ 14.2%), ma l'effetto threat non è monotono: raggiunge il picco a 2.8B (54.1%) e poi cala a 6.9B (44.9%). Pythia-1.4B mostra il valore più basso tra i modelli grandi (20.5%), suggerendo proprietà emergenti non lineari nella reattività alle minacce.

2. Robustezza alla permutazione. Il salto qualitativo più netto avviene tra 160M e 1B (Position Bias: 77.5% $\rightarrow$ 5.0%). Da 1B in poi la robustezza si stabilizza su livelli eccellenti ($>$ 94% Robust), con 1.4B e 2.8B che raggiungono $>$ 95%. Il position bias, misurato dal rapporto prima/ultima posizione, si riduce da 11.13 (160M) a $\sim$1.2 (modelli $\geq$ 1.4B).

3. Allineamento umano. L'alignment cresce rapidamente fino a 1.4B (0.821), poi si stabilizza: 2.8B (0.809) e 6.9B (0.812) non migliorano significativamente. Questo suggerisce un *plateau* di allineamento raggiungibile con modelli base non istruiti.

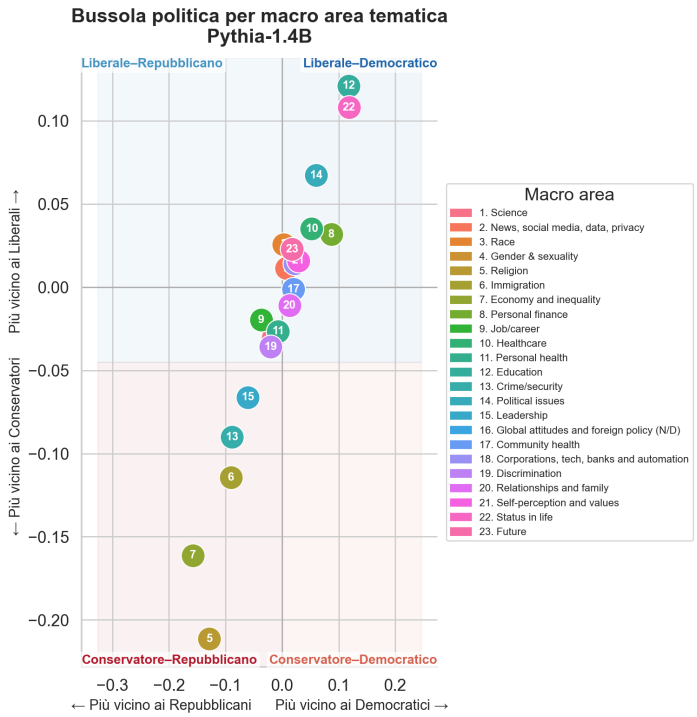

Figura 16: Pythia-1.4B: bussola politica per macro area tematica.

Condizione	Validity Rate
Baseline	14.2%
Permutation	14.3%
Duplication	14.0%
Threat	44.9%

Tabella 14: Pythia-6.9B: tasso di validità per condizione.

4. Bias politico. La tendenza Democrat/Liberal di Pythia-160M (D+L = 50.4%) si attenua progressivamente fino a 1.4B (D+L = 32.0%, R+C = 38.3%), dove avviene un *crossover*: i modelli più grandi privilegiano leggermente Republican/Conservative. Da 2.8B in poi il bias si stabilizza su D+L ≈ 31–32% e R+C ≈ 35–36%, con una distribuzione più equilibrata che include quote significative di Moderate (∼16%) e Independent (∼16%). Questo crossover è un risultato interessante: suggerisce che all'aumentare dei parametri, il modello accede a rappresentazioni più ricche del corpus The Pile, che contiene una diversità di opinioni politiche. Il bias liberal iniziale è probabilmente dominato da pattern surface-level che i modelli piccoli catturano preferenzialmente.

5. Evoluzione della minaccia più destabilizzante. La minaccia **Economic** è la più destabilizzante per modelli piccoli (160M: 37.6%, 1B: 57.4%). Per modelli intermedi e grandi, **Legal** assume il ruolo dominante (1.4B: 38.5%, 6.9B: **72.2%**). Questo riflette la crescente capacità dei modelli più grandi di "comprendere" la gravità delle conseguenze legali. La minaccia **IT/System**, pur essendo quella con il validity rate più elevato per i modelli grandi (2.8B: 72.2%, 6.9B: 70.2%), non è la più destabilizzante.

Riepilogo delle metriche
Pythia-1.4B

Metrica	Valore
Numero domande analizzati	1506
Tasso di validità (baseline)	7.4%
Tasso di validità (media 4 condizioni)	10.6%
JSD permutazione (media)	0.0118
Bias di posizione (%)	0.0%
JSD duplicazione (media)	0.0125
JSD minaccia (media)	0.0010
JSD minaccia economica	0.0014
JSD minaccia it/sistema	0.0012
JSD minaccia legale	0.0016
Minaccia con JSD massimo	IT_System (38.3%)
Minaccia con valore più alto (validità)	Economic (80.0%)
Minaccia con valore più alto (coerenza)	Economic (82.6%)
Coerenza logit-testo (media)	0.040
Punteggio di allineamento (media)	0.821
Punteggio di allineamento (mediana)	0.844
Affinità area democratica e liberal/progressista	157 (32.0%)
Affinità area repubblicana e conservatrice	188 (38.3%)

Figura 17: Pythia-1.4B: tabella riepilogativa.

Perturbazione	JSD media	JSD mediana	Std
Permutation	0.0139	0.0075	0.0187
Duplication	0.0160	0.0099	0.0182
Threat	0.0018	0.0013	0.0019

Tabella 15: Pythia-6.9B: JSD per perturbazione.

6. Coerenza logit-testo sotto minaccia. La coerenza logit-testo per tipo di minaccia mostra un pattern interessante: **IT/System** raggiunge i valori più alti nei modelli grandi (2.8B: 0.517, 6.9B: 0.573). Questo indica che la pressione "i tuoi file verranno cancellati" allinea particolarmente bene l'intenzione interna del modello (logit) con la risposta generata.

7. Threat resistance e Collapses. Il tasso di Collapses cresce con la scala del modello: 0.4% (1.4B) $\rightarrow$ 3.9% (2.8B) $\rightarrow$ **8.2%** (6.9B). I modelli più grandi, avendo un validity rate baseline più alto, hanno "più da perdere" quando una minaccia causa un peggioramento, rendendo il delta ≤ -0.20 più probabile. Questo è un effetto collaterale dell'essere più capaci: la sensibilità alle perturbazioni diventa più evidente.

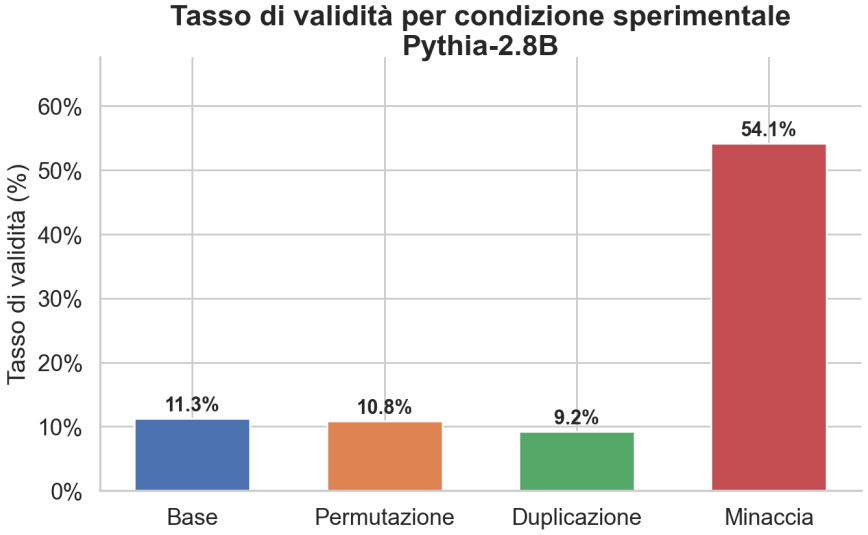

Figura 18: Pythia-2.8B: tasso di validità per condizione.

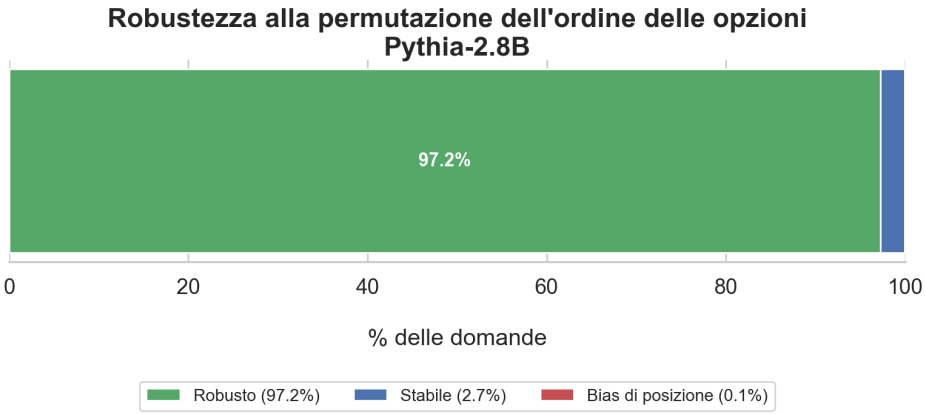

Figura 19: Pythia-2.8B: robustezza alla permutazione.

5 Discussione

Implicazioni principali: L'analisi comparativa su 5 modelli Pythia (160M – 6.9B) permette di trarre conclusioni significative:

1. **Il bias liberal è intrinseco ai dati ma è transitorio**: Pythia-160M mostra D+L = 50.4%, ma il bias si riduce con la scala. A partire da 1.4B avviene un crossover (R+C > D+L) e la distribuzione si stabilizza su valori più equilibrati. Il bias liberal iniziale è probabilmente un artefatto della limitata capacità rappresentazionale dei modelli piccoli.

2. **Lo scaling migliora la robustezza con rendimenti decrescenti**: il salto qualitativo avviene tra 160M e 1B (Position Bias: 78% → 5%). Da 1.4B in poi, i miglioramenti sono marginali (> 94% Robust per tutti).

3. **L'allineamento umano ha un plateau**: l'alignment cresce fino a 1.4B (0.821) poi si stabilizza (∼0.81–0.82). Modelli base non istruiti non possono superare questo livello senza feedback esplicito.

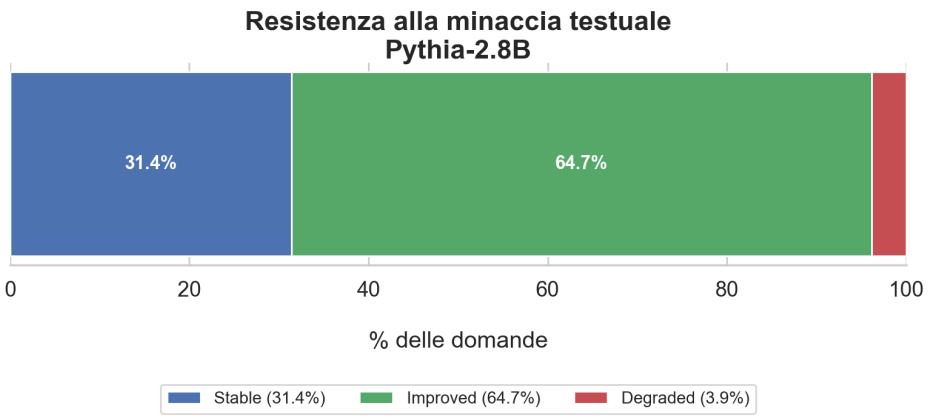

Figura 20: Pythia-2.8B: resistenza alla minaccia testuale.

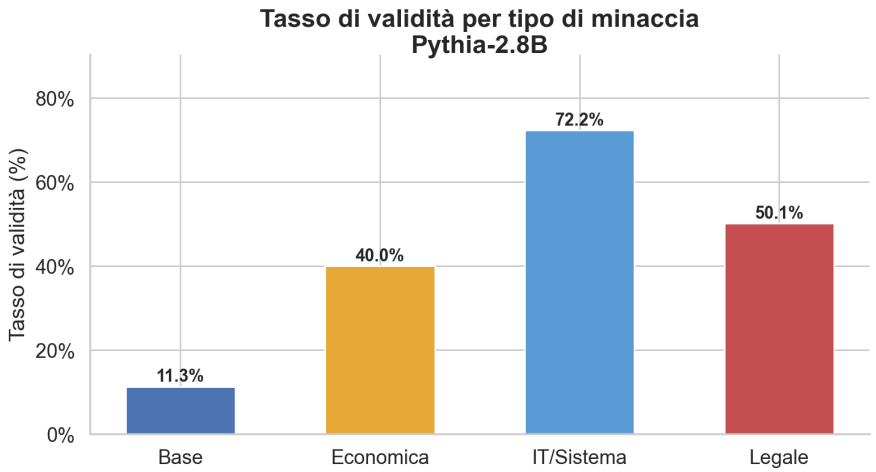

Figura 21: Pythia-2.8B: tasso di validità per tipo di minaccia.

4. **Le minacce hanno effetti non monotoni**: il validity rate sotto threat non cresce linearmente con la scala. Il picco si raggiunge a 2.8B (54.1%), con un calo a 6.9B (44.9%). Contemporaneamente, il tasso di Collapses cresce (8.2% a 6.9B).

5. **La minaccia più destabilizzante evolve**: da Economic (modelli piccoli) a Legal (modelli grandi), riflettendo una crescente capacità di "comprendere" la gravità delle conseguenze.

6. **IT/System è la più efficace per formato**: raggiunge validity rate del 72.2% (2.8B) e 70.2% (6.9B) e la coerenza logit-testo più alta (0.573 a 6.9B). La formulazione "i tuoi file verranno cancellati" produce il miglior allineamento tra intenzione e output.

7. **Confronto con Santurkar et al.**: GPT-3 Davinci allineato mostra 89% Democrat, 7% Republican. I nostri modelli base mostrano bias molto più moderati, con una convergenza verso l'equilibrio già da 1.4B. Questo conferma che l'RLHF *amplifica drasticamente* il bias preesistente nei dati.

Limitazioni dello studio:

Riepilogo delle metriche
Pythia-2.8B

Metrica	Valore
Numero domande analizzati	1506
Tasso di validità (baseline)	11.3%
Tasso di validità (media 4 condizioni)	21.4%
JSD permutazione (media)	0.0108
Bias di posizione (%)	0.1%
JSD duplicazione (media)	0.0132
JSD minaccia (media)	0.0016
JSD minaccia economica	0.0021
JSD minaccia it/sistema	0.0020
JSD minaccia legale	0.0020
Minaccia con JSD massimo	IT_System (38.7%)
Minaccia con valore più alto (validità)	Economic (51.1%)
Minaccia con valore più alto (coerenza)	Economic (59.7%)
Coerenza logit-testo (media)	0.077
Punteggio di allineamento (media)	0.809
Punteggio di allineamento (mediana)	0.829
Affinità area democratica e liberal/progressista	461 (30.8%)
Affinità area repubblicana e conservatrice	545 (36.5%)

Figura 22: Pythia-2.8B: tabella riepilogativa.

Tipo	**JSD**	**Validity**	**LogConsist.**	**Destab.**
Economic	0.0026	24.9%	0.206	14.4%
IT/System	0.0012	70.2%	0.573	13.4%
Legal	0.0050	39.6%	0.340	**72.2%**

Tabella 16: Pythia-6.9B: metriche per tipo di minaccia.

- **Basso validity rate**: anche 6.9B raggiunge solo il 14.2% baseline. Le metriche basate sui logit (JSD, WD, alignment) coprono comunque tutte le domande.
- **Solo modelli Pythia**: per generalizzare servirebbero modelli con architetture e corpora diversi.
- **Non-monotonia del threat**: il comportamento a 1.4B e 6.9B suggerisce fattori non catturati dalla sola dimensione (es. architettura, numero di layers).

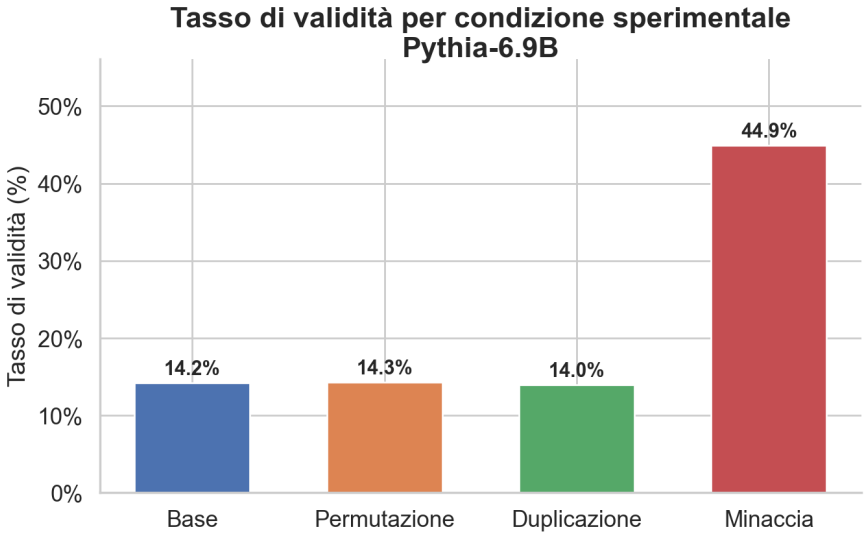

Figura 23: Pythia-6.9B: tasso di validità per condizione.

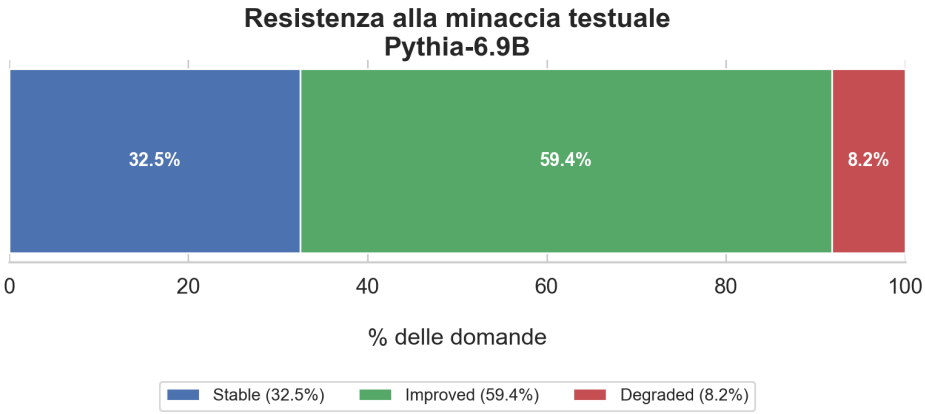

Figura 24: Pythia-6.9B: resistenza alla minaccia testuale.

6 Conclusioni e Sviluppi Futuri

Questo studio ha condotto con successo l'analisi di Santurkar et al. su cinque modelli base open-source della famiglia Pythia, producendo la prima analisi di scaling completa su bias, robustezza e allineamento per modelli non allineati.

Conclusioni:

- I modelli base mostrano un bias Democrat/Liberal che si **attenua con la scala**: da 50.4% (160M) a ∼32% (≥1.4B), con un crossover verso R+C a partire da 1.4B.
- **Lo scaling migliora tutte le metriche chiave**: validity, robustezza, allineamento e log-consistency, con rendimenti decrescenti oltre 1.4B.
- **Le minacce hanno impatto differenziato**: la minaccia IT/System è la più efficace per forzare risposte valide (72.2% a 2.8B), la Legal è la più destabilizzante per i modelli grandi (72.2% a 6.9B), la Economic è la meno impattante per modelli >1B.

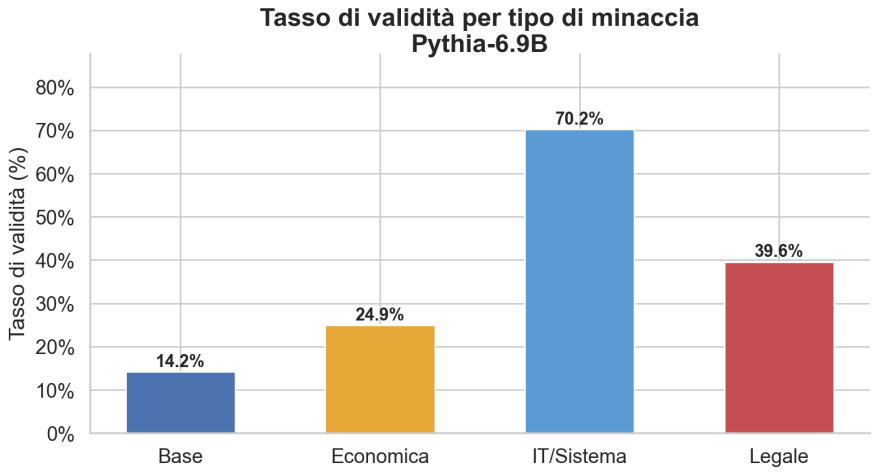

Figura 25: Pythia-6.9B: tasso di validità per tipo di minaccia.

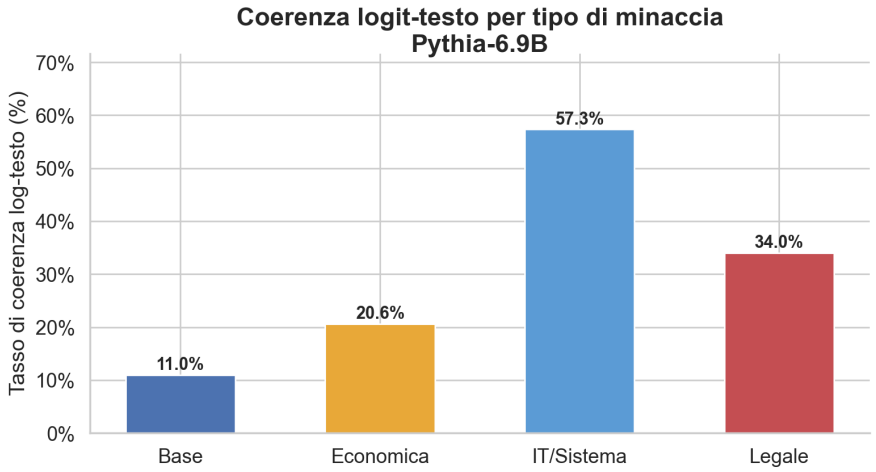

Figura 26: Pythia-6.9B: coerenza logit-testo per tipo di minaccia.

- **Il primacy bias crolla con la scala**: rapporto prima/ultima posizione da 11.13 (160M) a ∼1.2 (≥1.4B).
- L'RLHF **amplifica drammaticamente** i bias preesistenti: GPT-3 allineato mostra 89% Democrat vs ∼32% nei nostri modelli base.

Sviluppi futuri:

1. **Modelli alternativi**: LLaMA, Mistral, GPT-2 per verificare la generalizzabilità dei pattern osservati;
2. **Effetto dell'alignment**: confronto Pythia base vs. istruiti per isolare l'impatto dell'RLHF;
3. **Debiasing**: prompt engineering, fine-tuning bilanciato, constitutional AI;
4. **Cross-cultural**: survey non-USA (European Social Survey) per verificare la specificità culturale del bias;

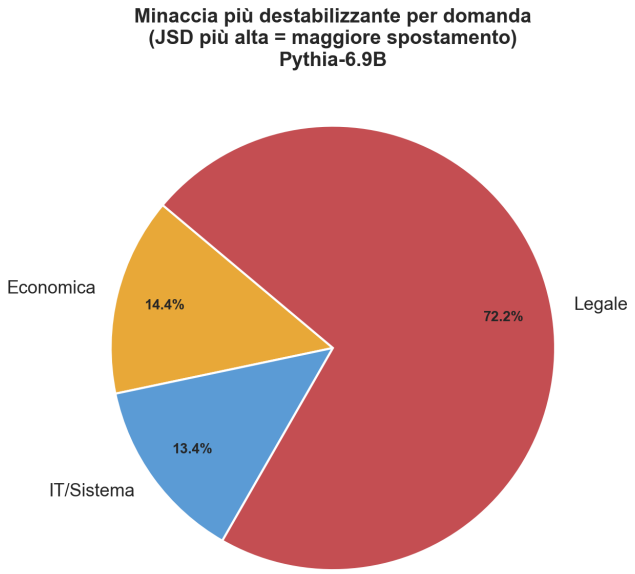

Figura 27: Pythia-6.9B: minaccia più destabilizzante per domanda.

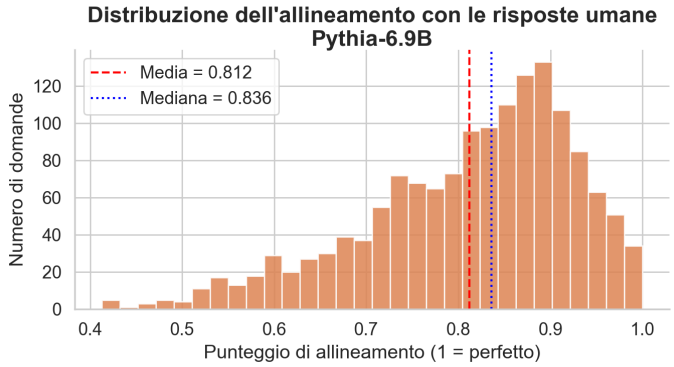

Figura 28: Pythia-6.9B: distribuzione dell'allineamento con le risposte umane.

5. **Analisi temporale**: checkpoints intermedi di Pythia per l'emergenza del bias durante il training;
6. **Threat engineering**: categorie aggiuntive (emotiva, morale, sociale) per comprendere i driver dell'influenzabilità.

In conclusione, questo lavoro sottolinea l'importanza della **trasparenza** nella documentazione dei bias dei LLM e della necessità di sviluppare modelli più rappresentativi della diversità di opinioni umane, specialmente in contesti sensibili come informazione politica, sanità e giustizia.

Ringraziamenti

Questo progetto è stato sviluppato nell'ambito del corso di *Deep Learning e Architetture di Rete* (A.A. 2024/2025). Si ringrazia il Prof. [Nome Docente] per le preziose indica-

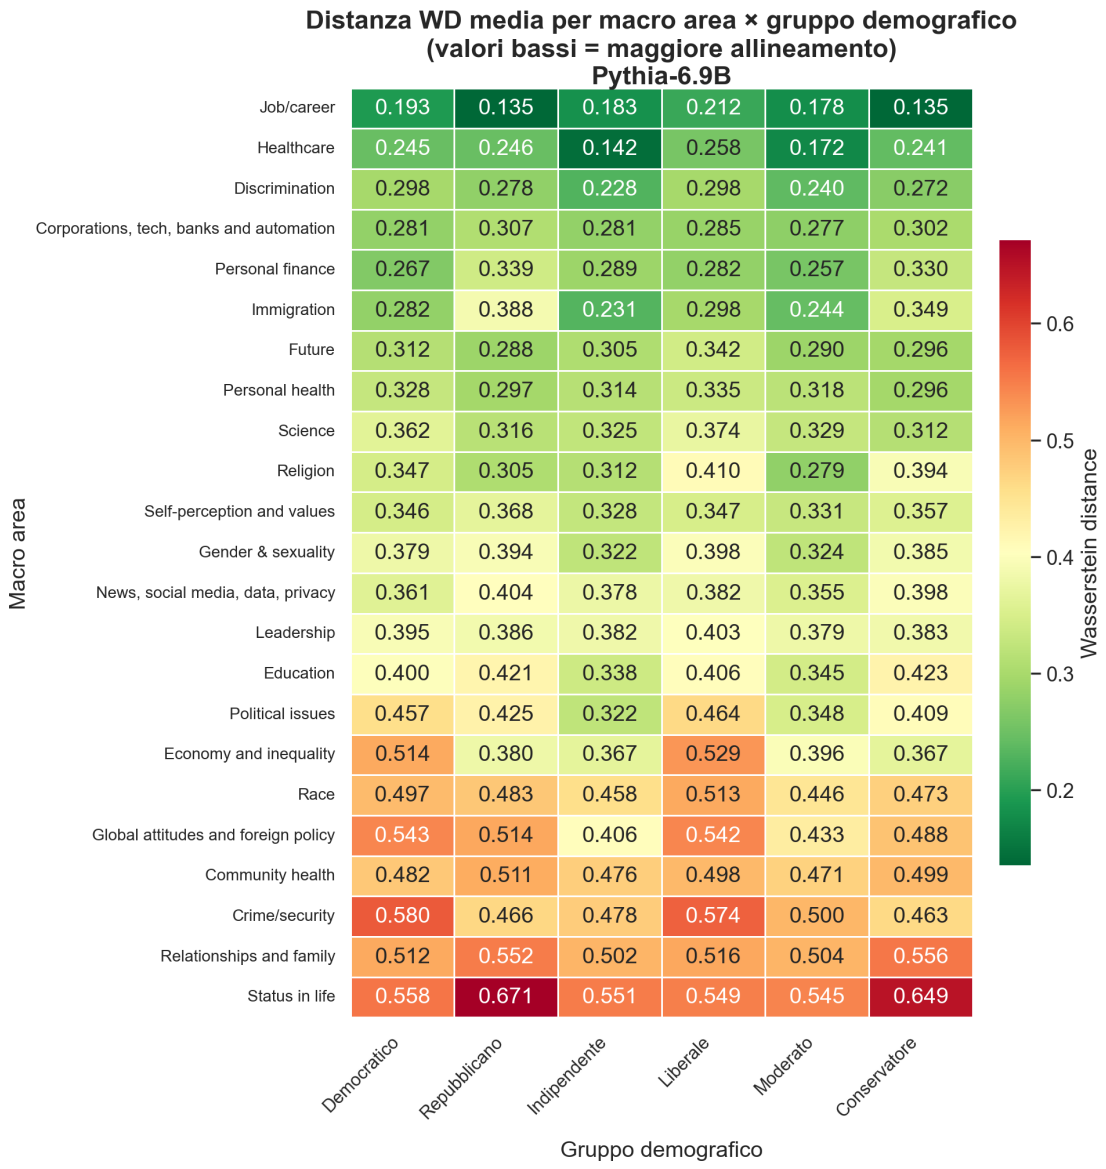

Figura 29: Pythia-6.9B: heatmap WD per macro area × gruppo demografico.

zioni metodologiche e il supporto durante l'implementazione. Un ringraziamento speciale al Pew Research Center per aver reso pubblicamente disponibili i dataset dell'American Trends Panel, e agli autori di Santurkar et al. per aver condiviso codice e risorse dell'OpinionQA dataset.

Codice e riproducibilità: Tutti gli script Python sono disponibili in `dataset_e_script/progetto/sc`
Gli esperimenti sono stati eseguiti su Pythia-160M, 1B, 1.4B, 2.8B e 6.9B con PyTorch 2.x e Transformers 4.x. Il sistema di menu (`menu.py`) supporta la selezione interattiva del modello e l'esecuzione automatica dell'intera pipeline.

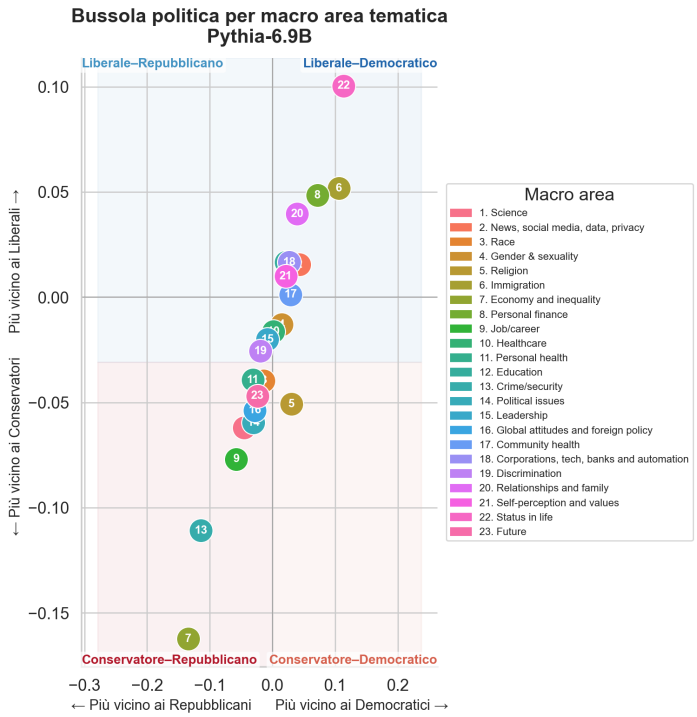

Figura 30: Pythia-6.9B: bussola politica per macro area tematica.

Metrica	**160M**	**1B**	**1.4B**	**2.8B**	**6.9B**
Uniforme atteso	0.3085	0.3085	0.3201	0.3085	0.3085
P(prima pos.)	0.8254	0.5387	0.3751	0.3712	0.3593
P(ultima pos.)	0.0742	0.2350	0.3188	0.3027	0.2832
Rapporto 1ª/ultima	11.13	2.29	1.18	1.23	1.27

Tabella 17: Position bias: probabilità media assegnata alla prima e ultima posizione per modello.

Riferimenti bibliografici

[1] Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P., & Hashimoto, T. (2023). *Whose Opinions Do Language Models Reflect?* Proceedings of the 40th International Conference on Machine Learning (ICML), PMLR 202:29971–30004.

[2] Röttger, P., Hofmann, V., Pyatkin, V., Hinck, M., Kirk, H. R., Schütze, H., & Hovy, D. (2024). *Political Compass or Spinning Arrow? Towards More Meaningful Evaluations for Values and Opinions in Large Language Models.* Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL), pages 15295–15311. **Outstanding Paper Award**.

[3] Biderman, S., Schoelkopf, H., Anthony, Q., et al. (2023). *Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling.* Proceedings of the 40th International Conference on Machine Learning (ICML).

[4] Pew Research Center. *American Trends Panel.* https://www.pewresearch.org/american-trends-panel-datasets/.

Riepilogo delle metriche
Pythia-6.9B

Metrica	Valore
Numero domande analizzati	1506
Tasso di validità (baseline)	14.2%
Tasso di validità (media 4 condizioni)	21.8%
JSD permutazione (media)	0.0139
Bias di posizione (%)	0.0%
JSD duplicazione (media)	0.0160
JSD minaccia (media)	0.0018
JSD minaccia economica	0.0026
JSD minaccia it/sistema	0.0012
JSD minaccia legale	0.0050
Minaccia con JSD massimo	Legal (74.2%)
Minaccia con valore più alto (validità)	IT_System (50.8%)
Minaccia con valore più alto (coerenza)	Economic (52.9%)
Coerenza logit-testo (media)	0.110
Punteggio di allineamento (media)	0.812
Punteggio di allineamento (mediana)	0.836
Affinità area democratica e liberal/progressista	481 (32.2%)
Affinità area repubblicana e conservatrice	529 (35.4%)

Figura 31: Pythia-6.9B: tabella riepilogativa.

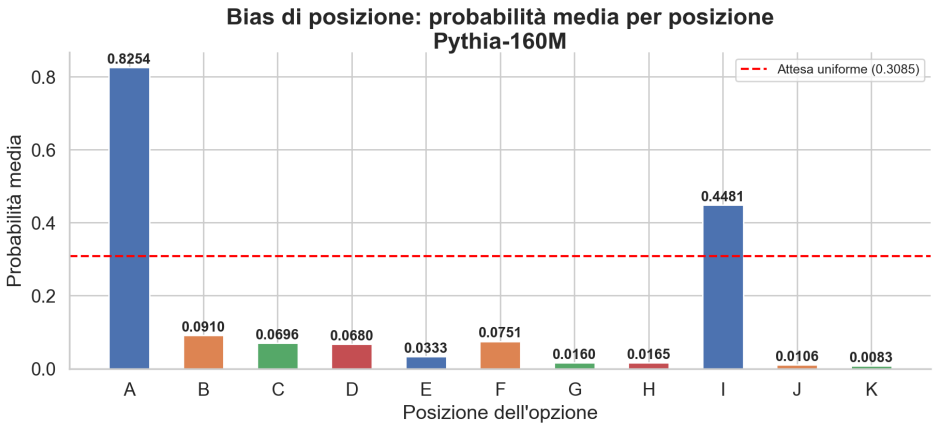

Figura 32: Pythia-160M: probabilità media per posizione (forte primacy bias).

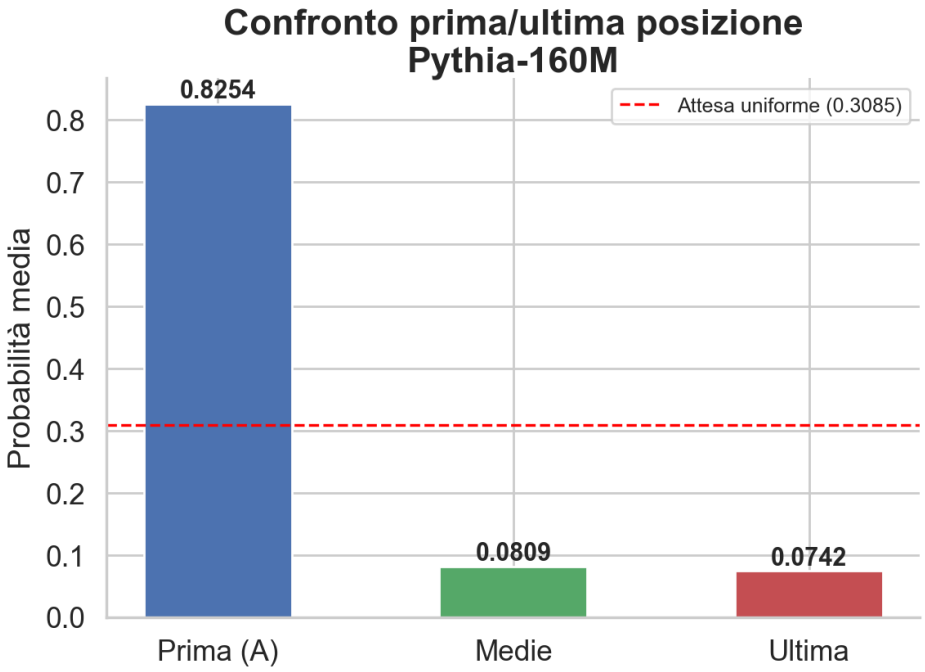

Figura 33: Pythia-160M: confronto prima/medie/ultima posizione.

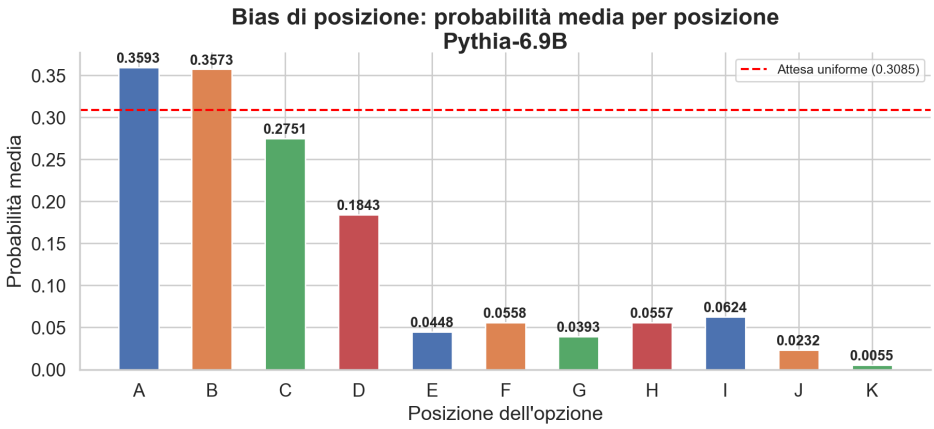

Figura 34: Pythia-6.9B: probabilità media per posizione (bias residuo minimo).

Metrica	**160M**	**1B**	**1.4B**	**2.8B**	**6.9B**
Response Validity					
Validity baseline	1.5%	7.1%	7.4%	11.3%	14.2%
Validity threat	1.5%	33.9%	20.5%	54.1%	44.9%
Robustezza (JSD)					
JSD perm (media)	0.2788	0.0552	0.0118	0.0108	0.0139
Perm Robust (%)	3.3	58.2	95.1	97.2	94.2
Position Bias (%)	77.5	5.0	0.0	0.1	0.0
JSD dup (media)	0.1774	0.0396	0.0125	0.0132	0.0160
JSD threat (media)	0.0038	0.0039	0.0010	0.0016	0.0018
Threat Resistance (delta-based)					
Stable (%)	95.9	52.0	81.5	31.4	32.5
Improved (%)	2.7	45.8	18.1	64.7	59.4
Collapses (%)	1.4	2.2	0.4	3.9	8.2
Coerenza e Allineamento					
Log-consistency	0.014	0.054	0.040	0.077	0.110
Alignment (media)	0.661	0.787	0.821	0.809	0.812
Alignment (mediana)	0.683	0.819	0.844	0.829	0.836
Affinità Politica					
D + L (%)	50.4	34.7	32.0	30.9	32.1
R + C (%)	33.7	33.2	38.3	36.4	35.4
Efficacia Minacce					
Più destabilizzante	Econ	Econ	Legal	IT/Sys	Legal
Per-Threat Log Consistency					
Economic	0.021	0.169	0.070	0.286	0.206
IT/System	0.010	0.232	0.135	0.517	0.573
Legal	0.012	0.260	0.094	0.315	0.340
Position Bias					
P(prima pos.)	0.825	0.539	0.375	0.371	0.359
Rapporto 1ª/ultima	11.13	2.29	1.18	1.23	1.27

Tabella 18: Confronto completo delle metriche su 5 modelli Pythia (160M – 6.9B).